

El objetivo de la práctica es estudiar las predicciones del IPI teniendo en cuenta el efecto calendario y efecto pascua. Además del efecto calendario y efecto pascua, estudiaremos las diferencias de extraer la tendencia de la serie de forma determinista y de forma estocástica.


Antes de estimar cualquier modelo debemos asegurarnos de extraer la tendencia, la estacionalidad y los efectos calendario y pascua, si existiesen. Además, tenemos que asegurarnos de eliminar la heterocedasticidad.

Para extraer la tendencia de la serie:

Si suponemos que la tendencia es determinista, utilizaremos las variables dummy para extraerla. Las variables dummy relacionan cada mes con diciembre.

Para captar la tendencia (representarla) en Eviews utilizamos la siguiente expresión:

`Tendencia=@trend+1`



Para extraer la tendencia de forma estocástica, como hacemos habitualmente, aplicamos la primera diferencia sobre el logaritmo del IPI. (este proceso está explicado en la práctica del IPI anterior a esta)

El siguiente paso sería eliminar el efecto calendario y pascua, si existiese. Este proceso se realiza tanto con el caso determinista como con el estocástico.

Efecto calendario:

Para incluir el efecto calendario en el modelo determinista utilizamos las variables V_{lunes} , V_{martes} , $V_{miercoles}$...

Tienen el mismo funcionamiento que las variables dummy. En este caso, V son los incrementos respecto al efecto de los domingos.

Efecto pascua:

Incluimos el efecto pascua añadiendo la variable DP . En este caso, DP sería el efecto de la semana de pascua sobre el resto de las semanas. (semana de pascua=1, resto=0)

Tanto para el ejemplo determinista como estocástico necesitamos estimar unos modelos que sean estacionarios. En primer lugar, incluimos el efecto de la tendencia en ambos modelos, en el caso determinista este viene explicado por las variables dummy mientras que en el caso estocástico eliminamos este efecto realizando una primera diferencia sobre los componentes regular y estacional. En segundo lugar, añadimos las variables explicativas del efecto calendario y pascua en los dos modelos. Por último, para que los modelos sean adecuados necesitamos que la estructura de los residuos se comporte como un ruido blanco, probaremos diferentes estructuras en cada uno de los modelos hasta lograrlo.

CASO NO DETERMINISTA:

Dependent Variable: D(LIPI,1,12)
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 04/30/20 Time: 20:09
Sample: 1976M02 2009M12
Included observations: 407
Convergence achieved after 11 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-0.000312	0.000489	-0.637493	0.5242
D(VLUNES,1,12)	0.001070	0.002525	0.423834	0.6719
D(VMARTES,1,12)	0.005206	0.002851	1.826090	0.0686
D(VMIERCOLES,1,12)	0.006117	0.002734	2.237349	0.0258
D(VJUEVES,1,12)	0.010697	0.002913	3.671512	0.0003
D(VVIERNES,1,12)	0.004872	0.002667	1.826603	0.0685
D(VSABADOS,1,12)	-0.013089	0.002880	-4.544781	0.0000
D(DP,1,12)	-0.041851	0.004216	-9.927834	0.0000
AR(1)	-0.606562	0.046648	-13.00289	0.0000
AR(2)	-0.209636	0.050079	-4.186085	0.0000
SAR(12)	-0.500321	0.052606	-9.510787	0.0000
SAR(24)	-0.295897	0.058369	-5.069387	0.0000
SIGMASQ	0.000873	5.49E-05	15.91920	0.0000



R-squared 0.756871 Mean dependent var -4.58E-05

CASO DETERMINISTA:

Dependent Variable: LIPI
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 03/03/20 Time: 10:27
Sample: 1975M01 2009M12
Included observations: 420
Convergence achieved after 14 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.094826	0.127883	32.01997	0.0000
TENDENCIA	0.001053	0.000456	2.307453	0.0215
DUMMY1	-0.008099	0.016048	-0.504682	0.6141
DUMMY2	0.004930	0.017334	0.284387	0.7763
DUMMY3	0.078048	0.015148	5.152229	0.0000
DUMMY4	0.029039	0.014242	2.038880	0.0421
DUMMY5	0.051994	0.017316	3.002686	0.0028
DUMMY6	0.048370	0.018284	2.645455	0.0085
DUMMY7	0.047968	0.014741	3.253976	0.0012
DUMMY8	-0.404899	0.013845	-29.24578	0.0000
DUMMY9	0.040481	0.020369	1.987338	0.0476
DUMMY10	0.077500	0.017660	4.388411	0.0000
DUMMY11	0.067691	0.021094	3.208952	0.0014
VLUNES	0.001398	0.002779	0.503222	0.6151
VMARTES	0.004082	0.003002	1.360000	0.1746
VMIERCOLES	0.006306	0.002840	2.220274	0.0270
VJUEVES	0.011143	0.002922	3.814067	0.0002
VVIERNES	0.004479	0.002675	1.674722	0.0948
VSABADOS	-0.012387	0.003095	-4.002488	0.0001
DP	-0.046989	0.004117	-11.41244	0.0000
AR(1)	0.389937	0.045803	8.513287	0.0000
AR(2)	0.369473	0.050017	7.386913	0.0000
AR(3)	0.159635	0.050979	3.131363	0.0019
SAR(12)	0.498783	0.050316	9.913070	0.0000
SAR(24)	0.253762	0.060131	4.220156	0.0000
SIGMASQ	0.000851	5.27E-05	16.14190	0.0000

R-squared 0.982990 Mean dependent var 4.361036



Una vez encontrada la estructura más adecuada para cada modelo, eliminamos los parámetros no significativos (al 10% en este caso). Los modelos elegidos para el caso determinista y estocástico son los siguientes:

CASO NO DETERMINISTA:

Dependent Variable: D(LIPI,1,12)
Method: Least Squares
Date: 04/30/20 Time: 20:12
Sample: 1976M02 2009M12
Included observations: 407
Convergence achieved after 12 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	-0.000311	0.000488	-0.637255	0.5243
D(VMARTES,1,12)	0.005801	0.002526	2.296796	0.0222
D(VMIERCOLES,1,12)	0.006110	0.002727	2.240547	0.0256
D(VJUEVES,1,12)	0.010638	0.002911	3.654120	0.0003
D(VVIERNES,1,12)	0.004810	0.002650	1.815037	0.0703
D(VSABADOS,1,12)	-0.013064	0.002871	-4.550622	0.0000
D(DP,1,12)	-0.041840	0.004211	-9.936484	0.0000
AR(1)	-0.607093	0.046573	-13.03522	0.0000
AR(2)	-0.208852	0.049789	-4.194743	0.0000
SAR(12)	-0.498172	0.052156	-9.551625	0.0000
SAR(24)	-0.297033	0.058270	-5.097485	0.0000
SIGMASQ	0.000874	5.47E-05	15.98391	0.0000

R-squared 0.756765 Mean dependent var -4.58E-05

CASO DETERMINISTA:

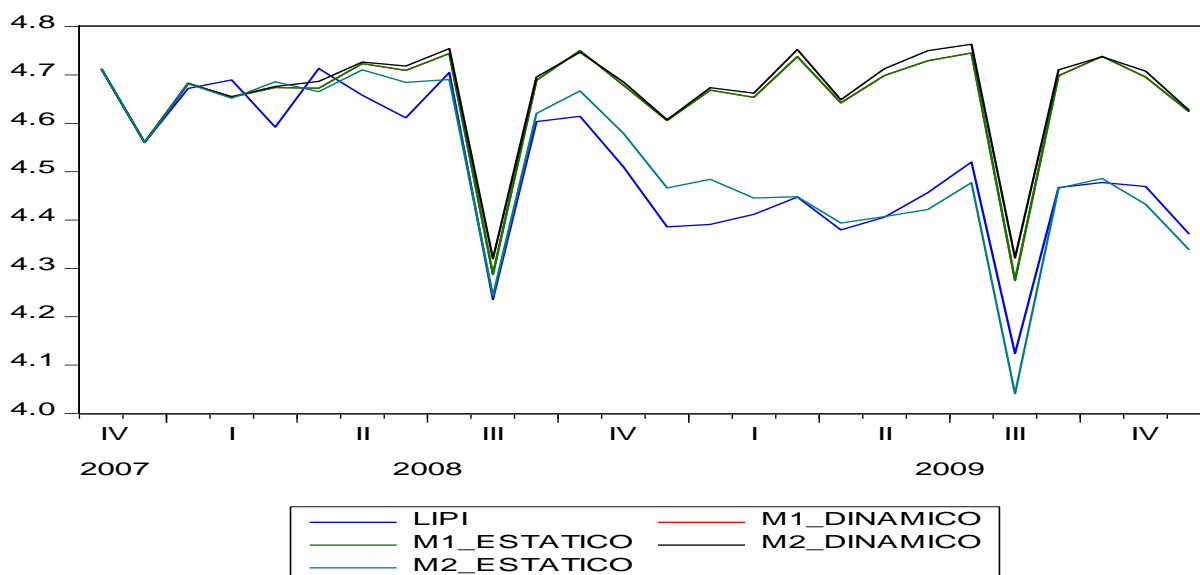
Dependent Variable: LIPI
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 03/12/20 Time: 11:37
Sample: 1975M01 2009M12
Included observations: 420
Convergence achieved after 13 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.094061	0.113109	36.19585	0.0000
TENDENCIA	0.001064	0.000417	2.551199	0.0111
DUMMY3	0.079543	0.014587	5.453108	0.0000
DUMMY4	0.029159	0.013555	2.151116	0.0321
DUMMY5	0.050530	0.016679	3.029569	0.0026
DUMMY6	0.047567	0.016474	2.887472	0.0041
DUMMY7	0.046716	0.013872	3.367692	0.0008
DUMMY8	-0.406415	0.012524	-32.45114	0.0000
DUMMY9	0.040446	0.018549	2.180517	0.0298
DUMMY10	0.077324	0.016905	4.574097	0.0000
DUMMY11	0.068114	0.019625	3.470830	0.0006
VMIERCOLES	0.009817	0.001998	4.912447	0.0000
VJUEVES	0.010788	0.002861	3.770897	0.0002
VVIERNES	0.004663	0.002648	1.761267	0.0790
VSABADOS	-0.012824	0.003057	-4.195346	0.0000
DP	-0.049514	0.003948	-12.54195	0.0000
AR(1)	0.402267	0.044808	8.977621	0.0000
AR(2)	0.357481	0.050031	7.145206	0.0000
AR(3)	0.157485	0.050074	3.145062	0.0018
SAR(12)	0.496153	0.050845	9.758225	0.0000
SAR(24)	0.251913	0.060080	4.192929	0.0000
SIGMASQ	0.000863	5.37E-05	16.06026	0.0000

R-squared 0.982746 Mean dependent var 4.361036

LAS PREDICCIONES:

Llamaremos M1 al caso NO determinista y M2 al caso determinista.



Para saber qué modelo comete menos errores de predicción calculamos el sumatorio de los errores al cuadrado de cada predicción:

M1 DINÁMICO	M1 ESTÁTICO	M2 DINÁMICO	M2 ESTÁTICO
0.066171489	0.066171489	0.130331035	0.034209354

De esta forma comprobamos que la predicción no determinista se ajusta mejor a la realidad en el caso de predicción dinámica y el caso determinista en la estática.

De todas formas, son muy similares.