


PRÁCTICA 1: PIB ESPAÑOL

Se nos proporciona una serie temporal con el PIB anual español desde 1820 hasta 2008. Desde 1821 hasta 1849, no existen datos para la serie.




Nuestro objetivo a continuación es elaborar predicciones del PIB entre 2004 y 2008 mediante tres sistemas diferentes:























- Una diferencia
- Diferencia del logaritmo
- Dos diferencias

Una diferencia

En primer lugar, transformamos la serie tomando una diferencia. El resultado es el siguiente:



A continuación, observamos el correlograma para decidir qué modelo escoger.

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob	
		1	0.757	0.757	92.205	0.000
		2	0.633	0.142	157.22	0.000
		3	0.551	0.078	206.79	0.000
		4	0.488	0.047	245.93	0.000
		5	0.479	0.132	283.77	0.000
		6	0.438	0.003	315.67	0.000
		7	0.417	0.051	344.73	0.000
		8	0.413	0.072	373.42	0.000
		9	0.409	0.061	401.84	0.000
		10	0.398	0.021	428.92	0.000
		11	0.392	0.045	455.28	0.000

En la columna que indica la autocorrelación simple, todas las barras exceden los límites. Como, además, la primera barra de la correlación parcial excede ampliamente los límites, y los valores siguientes son muy cercanos a cero, hemos decidido tomar un modelo AR(1).


Dependent Variable: DSPAIN
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 02/12/20 Time: 22:29
Sample: 1851 2008
Included observations: 158
Convergence achieved after 12 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	116.5902	44.63348	2.612170	0.0099
AR(1)	0.753519	0.042423	17.76194	0.0000
SIGMASQ	17566.43	1314.948	13.35903	0.0000

R-squared	0.573753	Mean dependent var	117.8960
Adjusted R-squared	0.568253	S.D. dependent var	203.6525
S.E. of regression	133.8149	Akaike info criterion	12.65491
Sum squared resid	2775496.	Schwarz criterion	12.71306
Log likelihood	-996.7376	Hannan-Quinn criter.	12.67852
F-statistic	104.3194	Durbin-Watson stat	2.164961
Prob(F-statistic)	0.000000		

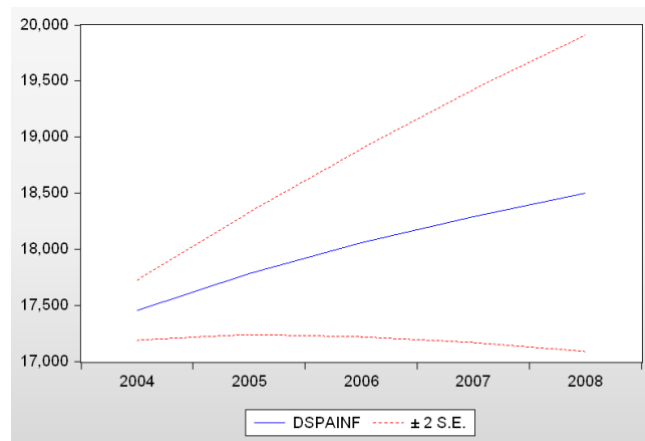
Inverted AR Roots	.75
-------------------	-----

Para verificar que el modelo es propicio, debemos asegurarnos de que los residuos son ruido blanco.




Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 -0.108	-0.108	1.8739	
		2 0.017	0.006	1.9235	0.165
		3 0.047	0.050	2.2813	0.320
		4 -0.023	-0.013	2.3662	0.500
		5 0.123	0.119	4.8561	0.302
		6 0.029	0.055	4.9995	0.416
		7 0.029	0.037	5.1386	0.526
		8 0.057	0.054	5.6889	0.577
		9 0.074	0.088	6.6167	0.578
		10 0.050	0.054	7.0467	0.632
		11 0.081	0.082	8.1645	0.613
		12 0.117	0.129	10.543	0.482
		13 -0.030	-0.016	10.704	0.554
		14 0.018	-0.016	10.761	0.631

Finalmente, lanzamos el forecast para el periodo 2004-2008.



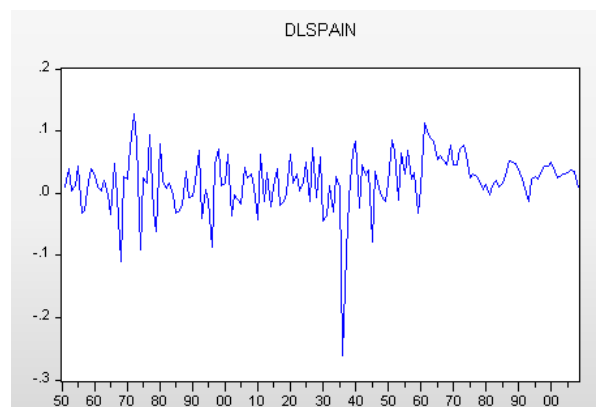
El resultado es el siguiente:



Como podemos observar, esta predicción es notoriamente inferior a los valores reales. Una posible explicación sería la influencia de los valores comprendidos entre 1850 y 1950, que distan mucho de los últimos valores de la serie, pero en nuestro modelo AR(1) siguen ejerciendo su influencia a la baja.

Diferencia de la transformación logarítmica

En primer lugar, transformamos la serie tomando la diferencia del logaritmo.



A continuación, observamos el correlograma para decidir qué modelo escoger.

Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.223	0.223	7.9953	0.005
		2	0.039	-0.011	8.2392	0.016
		3	0.040	0.036	8.4993	0.037
		4	0.033	0.018	8.6781	0.070
		5	0.140	0.135	11.911	0.036
		6	0.079	0.019	12.953	0.044
		7	0.039	0.016	13.212	0.067
		8	0.081	0.066	14.329	0.074
		9	0.088	0.056	15.656	0.074
		10	0.082	0.035	16.803	0.079
		11	0.157	0.127	21.053	0.033


Como no sabemos identificar a través el correlograma el modelo más indicado para este caso, vamos a probar con un modelo ARMA(1,1).

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.018351	0.005305	3.459282	0.0007
AR(1)	0.150037	0.431114	0.348023	0.7283
MA(1)	0.075105	0.442769	0.169626	0.8655
SIGMASQ	0.001965	0.000118	16.67142	0.0000
R-squared	0.049870	Mean dependent var		0.018387
Adjusted R-squared	0.031361	S.D. dependent var		0.045626
S.E. of regression	0.044905	Akaike info criterion		-3.343221
Sum squared resid	0.310535	Schwarz criterion		-3.265687
Log likelihood	268.1145	Hannan-Quinn criter.		-3.311734
F-statistic	2.694369	Durbin-Watson stat		1.997249
Prob(F-statistic)	0.048048			
Inverted AR Roots	.15			
Inverted MA Roots	-.08			

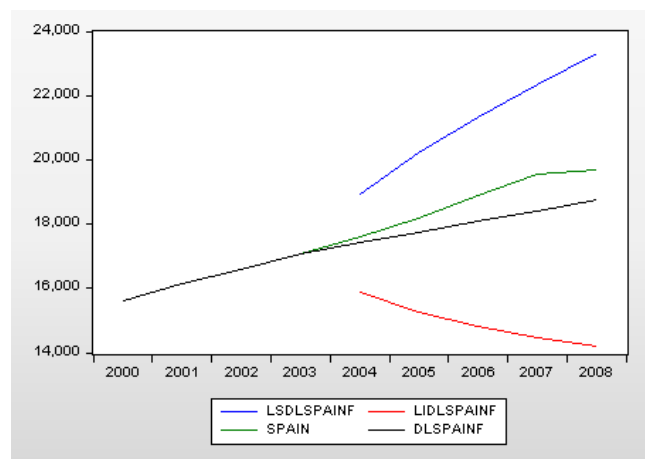
Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.001	0.001	0.0001	
		2	-0.002	-0.002	0.0010	
		3	0.032	0.032	0.1665	0.683
		4	-0.005	-0.005	0.1707	0.918
		5	0.129	0.129	2.9151	0.405
		6	0.046	0.046	3.2697	0.514
		7	0.009	0.011	3.2826	0.657
		8	0.062	0.055	3.9247	0.687
		9	0.062	0.062	4.5676	0.713
		10	0.035	0.020	4.7741	0.781
		11	0.128	0.118	7.6031	0.575
		12	0.088	0.088	8.9552	0.536
		13	-0.033	-0.045	9.1504	0.608
		14	0.062	0.041	9.8232	0.631
		15	-0.044	-0.059	10.161	0.681
		16	-0.118	-0.160	12.632	0.556
		17	0.129	0.088	15.598	0.409
		18	0.002	-0.003	15.598	0.481
		19	0.054	0.031	16.131	0.515
		20	-0.112	-0.142	18.439	0.427
		21	0.054	0.087	18.983	0.458
		22	0.095	0.056	20.661	0.417
		23	0.043	0.029	21.003	0.459
		24	-0.041	-0.037	21.328	0.501
		25	-0.119	-0.100	24.003	0.404

Con el correlograma de los residuos observamos que los residuos se comportan de manera muy aleatoria, siendo la mayoría cero o próximos a cero. Así pues, asumiremos que son ruido blanco.

Lanzamos un forecast para 2004-2008.




Este es el resultado final:




La predicción es mucho mejor. Los valores predcidos siguen siendo inferiores por el peso de los años anteriores.

Dos diferencias

En primer lugar, transformamos la serie tomando dos diferencias. El resultado es el siguiente:

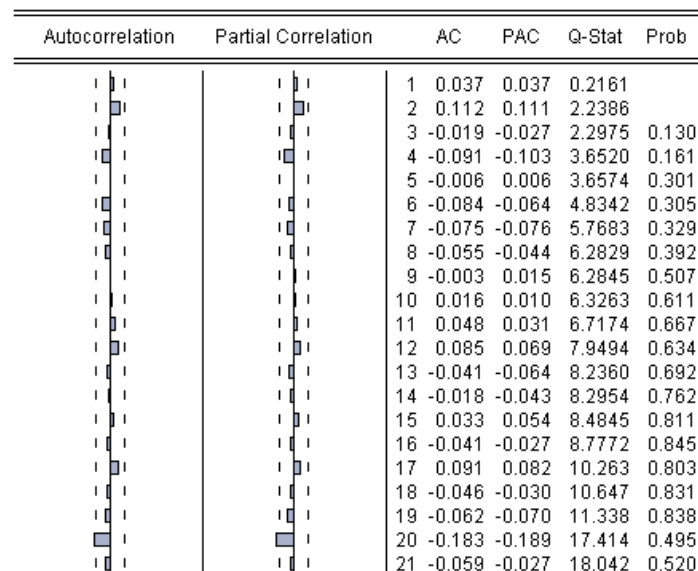


A continuación, observamos el correlograma para decidir qué modelo escoger.




Tampoco tenemos claro qué modelo elegir. Probaremos con un MA(2).

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	3.044567	2.279059	1.335888	0.1836
MA(1)	-0.494818	0.087473	-5.656815	0.0000
MA(2)	-0.308347	0.091033	-3.387210	0.0009
SIGMASQ	16404.88	1365.007	12.01817	0.0000
R-squared	0.183681	Mean dependent var		0.920371
Adjusted R-squared	0.167675	S.D. dependent var		142.2146
S.E. of regression	129.7450	Akaike info criterion		12.60001
Sum squared resid	2575567.	Schwarz criterion		12.67787
Log likelihood	-985.1005	Hannan-Quinn criter.		12.63163
F-statistic	11.47559	Durbin-Watson stat		1.857033
Prob(F-statistic)	0.000001			
Inverted MA Roots	.86	-.36		




Con el correlograma de los residuos observamos que los residuos se comportan de manera muy aleatoria, siendo la mayoría cero o próximos a cero. Así pues, asumiremos que son ruido blanco.

Finalmente, lanzamos el forecast.



Este es el resultado final:



La predicción, en la línea de las demás, tiende a ser inferior a los valores reales. Para mejorar todas las predicciones, tal vez deberíamos tomar solamente valores más recientes de la serie.

